UNIVERSITAT POLITÈCNICA DE VALÈNCIA

etsinf
Escola Tècnica Superior d'Enginyeria Informàtica

Escuela Técnica Superior de Ingeniería Informática
Universitat Politècnica de València

Introducción a las Redes Neuronales Artificiales: Fundamentos y Aplicaciones

Trabajo de Fin de Grado

Grado en Ciencia de Datos

Autor: Ernesto Martínez Gómez
Tutor: Fernando Martínez Gómez
Imad Rifai

Curso 2025/2026

Resumen

Las redes neuronales artificiales han revolucionado el campo del aprendizaje automático en las últimas décadas. Este trabajo presenta una introducción completa a los fundamentos teóricos de las redes neuronales, desde el perceptrón simple hasta arquitecturas complejas como redes convolucionales y recurrentes. Se analizan los principales algoritmos de entrenamiento, funciones de activación y técnicas de regularización. Además, se exploran aplicaciones prácticas en diversos dominios como visión por computador, procesamiento de lenguaje natural y sistemas recomendadores. El objetivo es proporcionar una base sólida para comprender el funcionamiento interno de estas herramientas omnipresentes en la inteligencia artificial moderna.

Palabras clave: Redes Neuronales, Aprendizaje Profundo, Perceptrón, Backpropagation, CNN, RNN, Inteligencia Artificial, Machine Learning

Resum

Les xarxes neuronals artificials han revolucionat el camp de l'aprenentatge automàtic en les últimes dècades. Aquest treball presenta una introducció completa als fonaments teòrics de les xarxes neuronals, des del perceptró simple fins a arquitectures complexes com xarxes convolucionals i recurrents. S'analitzen els principals algorismes d'entrenament, funcions d'activació i tècniques de regularització. A més, s'exploren aplicacions pràctiques en diversos dominis com visió per computador, processament del llenguatge natural i sistemes recomanadors. L'objectiu és proporcionar una base sòlida per a comprendre el funcionament intern d'aquestes eines omnipresents en la intel·ligència artificial moderna.

Paraules clau: Xarxes Neuronals, Aprenentatge Profund, Perceptró, Backpropagation, CNN, RNN, Intel·ligència Artificial, Machine Learning

Abstract

Artificial neural networks have revolutionized the field of machine learning in recent decades. This work presents a comprehensive introduction to the theoretical foundations of neural networks, from the simple perceptron to complex architectures such as convolutional and recurrent networks. The main training algorithms, activation functions, and regularization techniques are analyzed. Furthermore, practical applications in various domains such as computer vision, natural language processing, and recommender systems are explored. The goal is to provide a solid foundation for understanding the internal workings of these ubiquitous tools in modern artificial intelligence.

Key words: Neural Networks, Deep Learning, Perceptron, Backpropagation, CNN, RNN, Artificial Intelligence, Machine Learning

Índice

Índice ..... **iv**
Índice de figuras ..... **v**
Índice de tablas ..... **vi**
Índice de algoritmos ..... **vii**

1. Introducción **1**
1.1. Motivación y Contexto 1
1.2. Objetivos 1
2. Fundamentos Teóricos **3**
2.1. El Perceptrón 3
2.1.1. Modelo Matemático 3
2.1.2. Funciones de Activación 3
2.2. Redes Multicapa (MLP) 3
2.2.1. Arquitectura 4
2.2.2. Algoritmo de Retropropagación 4
3. Arquitecturas Avanzadas **5**
3.1. Redes Convolucionales (CNN) 5
3.1.1. Operación de Convolución 5
3.1.2. Componentes Principales 5
3.2. Redes Recurrentes (RNN) 5
3.2.1. Estructura Recurrente 5
3.2.2. Variantes Modernas 5
4. Aplicaciones Prácticas **7**
4.1. Visión por Computador 7
4.2. Procesamiento de Lenguaje Natural 7
5. Técnicas de Regularización **9**
5.1. Dropout 9
5.2. Normalización por Lotes (Batch Normalization) 9
6. Conclusiones **11**
7. Trabajo Futuro **13**

Índice de figuras

Cuadro 1 Arquitectura típica de una red neuronal multicapa 4
Cuadro 2 Componentes principales de una CNN 5
Figura 1 Aplicaciones de redes neuronales en visión por computador 7
Cuadro 3 Aplicaciones de NLP basadas en redes neuronales 7

Índice de tablas

Tabla 1 Funciones de activación más utilizadas en redes neuronales 3
Tabla 2 Best obtained results for each neural family 13

Índice de algoritmos

Algoritmo 1 Algoritmo de Retropropagación (simplificado) 4

CAPÍTULO 1

Introducción

Las redes neuronales artificiales representan uno de los paradigmas más importantes en el campo de la inteligencia artificial y el aprendizaje automático. Inspiradas en la estructura biológica del cerebro humano, estas redes están compuestas por unidades de procesamiento interconectadas que pueden aprender patrones complejos a partir de datos.

El objetivo de este trabajo es proporcionar una introducción accesible pero rigurosa a los fundamentos de las redes neuronales, desde los conceptos más básicos hasta las arquitecturas más avanzadas utilizadas en la actualidad.

1.1. Motivación y Contexto

En los últimos años, hemos presenciado un avance extraordinario en las capacidades de los sistemas de inteligencia artificial. Desde el reconocimiento de imágenes que supera la capacidad humana hasta modelos de lenguaje que pueden generar texto coherente, las redes neuronales están en el centro de estas innovaciones.

1.2. Objetivos

Los principales objetivos de este trabajo son:

- Comprender los fundamentos matemáticos de las redes neuronales
- Analizar diferentes arquitecturas y sus aplicaciones
- Estudiar los algoritmos de entrenamiento
- Explorar técnicas de regularización y optimización

CAPÍTULO 2

Fundamentos Teóricos

2.1. El Perceptrón

El perceptrón, introducido por Frank Rosenblatt en 1958, es la unidad fundamental de una red neuronal. Es un algoritmo de clasificación binaria que aprende un hiperplano de separación óptimo.

2.1.1. Modelo Matemático

La salida de un perceptrón se calcula mediante la siguiente función:

$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right) = f(\boldsymbol{w}^\top \boldsymbol{x} + b) \tag{1}$$

donde $\boldsymbol{w}$ representa los pesos, $\boldsymbol{x}$ las entradas, b el sesgo, y f la función de activación.

2.1.2. Funciones de Activación

Las funciones de activación introducen no linealidades en la red, permitiendo aprender patrones complejos. Las más comunes son:

Nombre	Definición	Rango
Sigmoide	$\sigma(x) = \frac{1}{1+e^{-x}}$	$(0, 1)$
Tanh	$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	$(-1, 1)$
ReLU	$\mathrm{ReLU}(x) = \max(0, x)$	$[0, +\infty)$
Leaky ReLU	$f(x) = \max(\alpha x, x)$	$(-\infty, +\infty)$

Tabla 1: Funciones de activación más utilizadas en redes neuronales

2.2. Redes Multicapa (MLP)

Una red neuronal multicapa (Multi-Layer Perceptron) consiste en múltiples capas de perceptrones organizados de forma jerárquica.

2.2.1. Arquitectura

Capa de entrada Capa oculta Capa de salida

Cuadro 1: Arquitectura típica de una red neuronal multicapa

2.2.2. Algoritmo de Retropropagación

El algoritmo de retropropagación (*backpropagation*) es el método fundamental para entrenar redes neuronales multicapa. Se basa en la regla de la cadena del cálculo diferencial para calcular gradientes de manera eficiente.

Algoritmo 1: Algoritmo de Retropropagación (simplificado)

1. **Propagación hacia adelante**: Se calculan las salidas de la red capa por capa
2. **Cálculo del error**: Se compara la salida obtenida con la esperada
3. **Propagación hacia atrás**: Se calculan los gradientes del error respecto a cada peso
4. **Actualización de pesos**: Se ajustan los pesos usando gradiente descendente

La actualización de pesos sigue la regla del gradiente descendiente:

$$w_{ij}^{l} := w_{ij}^{l} - \eta \frac{\partial L}{\partial w_{ij}^{l}} \tag{2}$$

donde η es la tasa de aprendizaje y L es la función de pérdida.

CAPÍTULO 3

Arquitecturas Avanzadas

3.1. Redes Convolucionales (CNN)

Las redes neuronales convolucionales (CNN) están especialmente diseñadas para procesar datos con estructura de cuadrícula, como imágenes.

3.1.1. Operación de Convolución

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \tag{3}$$

donde I es la imagen de entrada y K es el kernel o filtro.

3.1.2. Componentes Principales

Capa convolucional	Aplica filtros para detectar características locales
Capa de pooling	Reduce la dimensionalidad espacial
Capa fully-connected	Conecta todas las neuronas para la clasificación final

Cuadro 2: Componentes principales de una CNN

La operación de convolución en 2D se define como:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \tag{4}$$

donde I es la imagen de entrada y K es el kernel o filtro.

3.2. Redes Recurrentes (RNN)

Las redes neuronales recurrentes están diseñadas para procesar secuencias de datos, como series temporales o texto.

3.2.1. Estructura Recurrente

En una RNN, la salida en un paso de tiempo depende tanto de la entrada actual como del estado oculto anterior:

$$\boldsymbol{h}_t = f(\boldsymbol{W}_{hh}\boldsymbol{h}_{t-1} + \boldsymbol{W}_{xh}\boldsymbol{x}_t + \boldsymbol{b}_h) \tag{5}$$

$$\boldsymbol{y}_t = g\big(\boldsymbol{W}_{hy}\boldsymbol{h}_t + \boldsymbol{b}_y\big) \tag{6}$$

3.2.2. Variantes Modernas

Para abordar el problema del desvanecimiento del gradiente en secuencias largas, se han desarrollado arquitecturas como:

- **LSTM** (Long Short-Term Memory): Utiliza compuertas de olvido, entrada y salida

- **GRU** (Gated Recurrent Unit): Simplificación del LSTM con menos parámetros

CAPÍTULO 4

Aplicaciones Prácticas

Las redes neuronales han encontrado aplicaciones en prácticamente todos los campos de la tecnología moderna.

4.1. Visión por Computador

Figura 1: Aplicaciones de redes neuronales en visión por computador

Algunas aplicaciones destacadas incluyen:

- Detección y reconocimiento de objetos
- Segmentación semántica de imágenes
- Reconocimiento facial
- Conducción autónoma

4.2. Procesamiento de Lenguaje Natural

Las redes neuronales han transformado el procesamiento del lenguaje natural:

Tarea	Descripción	Arquitectura
Traducción automática	Traducir texto entre idiomas	Transformer
Análisis de sentimiento	Clasificar polaridad emocional	RNN, BERT
Generación de texto	Crear contenido coherente	GPT, T5
Respuesta a preguntas	Sistemas de Q&A	BERT, RoBERTa

Cuadro 3: Aplicaciones de NLP basadas en redes neuronales

CAPÍTULO 5

Técnicas de Regularización

Para evitar el sobreajuste en redes neuronales profundas, se utilizan diversas técnicas de regularización.

5.1. Dropout

El dropout desactiva aleatoriamente neuronas durante el entrenamiento:

$$y = f(\boldsymbol{W} \cdot \text{dropout}(\boldsymbol{x}, p) + \boldsymbol{b}) \tag{7}$$

donde p es la probabilidad de desactivar una neurona.

5.2. Normalización por Lotes (Batch Normalization)

Normaliza las activaciones de cada capa:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} \tag{8}$$

$$y_i = \gamma \hat{x}_i + \beta \tag{9}$$

CAPÍTULO 6

Conclusiones

Las redes neuronales artificiales representan una de las herramientas más poderosas en el arsenal de la inteligencia artificial moderna. Desde sus humildes comienzos con el perceptrón simple hasta las sofisticadas arquitecturas actuales como Transformers y GANs, estas redes han demostrado una capacidad extraordinaria para aprender representaciones complejas de datos.

Los principales puntos clave de este trabajo son:

1. Los fundamentos matemáticos del perceptrón y la retropropagación siguen siendo relevantes hoy en día
2. Diferentes arquitecturas están diseñadas para diferentes tipos de datos y problemas
3. Las técnicas de regularización son esenciales para redes profundas
4. Las aplicaciones prácticas abarcan desde la visión por computador hasta el procesamiento del lenguaje natural

El campo continúa evolucionando rápidamente, con nuevas arquitecturas y técnicas emergiendo constantemente. La comprensión de estos fundamentos proporciona una base sólida para seguir los avances futuros en este campo fascinante.

CAPÍTULO 7

Trabajo Futuro

Como líneas de trabajo futuro, se podrían explorar:

- Implementación práctica de las arquitecturas descritas utilizando frameworks modernos como PyTorch o TensorFlow
- Estudio de arquitecturas más recientes como Vision Transformers (ViT) y modelos de difusión
- Análisis de las implicaciones éticas y sociales de los sistemas de inteligencia artificial basados en redes neuronales
- Optimización de redes neuronales para dispositivos con recursos limitados (*edge computing*)

Family	**Binary**	**Multiclass**
Feed-Forward	0.65	0.19
CNN	0.57	0.18
RNN	**0.70**	**0.26**
TDNN	0.69	**0.26**

Tabla 2: Best obtained results for each neural family